Universidade Federal do Ceará, Departamento de Estatística e Matemática Aplicada Introdução à Mineração de Dados (CC0101), período 2019.2

Professor: Tibérius O. Bonates (tb@ufc.br).

Atividade 5 - Validação cruzada.

1 Descrição

1.1 Parte 1 (1,5 pontos)

Utilize o módulo Experimenter do WEKA para realizar uma série de experimentos de k-fold com diferentes algoritmos de classificação (utilizando diferentes configurações de hiperparâmetros dos mesmos) e diferentes conjuntos de dados. O intuito da atividade é fazer um ranking dos diversos classificadores testados em termos de acurácia média.

Sua equipe pode ficar à vontade para escolher os algoritmos e as **configurações de seus hiperparâmetros**. No entanto, um número total de 10 (dez) classificadores diferentes devem ser utilizados. Além disso, dentre os 10 classificadores, deve existir **pelo menos**:

- 2 (dois) classificadores do tipo Multilayer Perceptron (mas com diferentes escolhas de hiperâmetros);
- 2 (dois) do tipo SMO (mas com diferentes escolhas de hiperâmetros); e
- 2 (dois) do tipo J48 (mas com diferentes escolhas de hiperâmetros).

Cada classificador deve ser testado em termos de 10 (dez) experimentos de validação cruzada do tipo 10-fold.

Os conjuntos de dados a serem utilizados devem ser: (a) breast-cancer.arff; (b) credit-g.arff; (c) diabetes.arff; e (d) ionosphere.arff.

Os resultados de seus testes devem ser reportados no arquivo PDF a ser entregue, e devem ser expressos em termos de acurácias médias. Naturalmente, sua equipe deve me informar no arquivo PDF quais foram exatamente os classificadores utilizados e seus hiperparâmetros. Eu devo receber um arquivo CSV gerado pelo WEKA Experimenter, para que eu possa validar seus resultados.

Se algum dos itens solicitados nesta parte estiver ausente, sua atividade pode receber crédito zero nesta parte. Leia e releia estas instruções com atenção, para evitar decepções. Em caso de dúvida, contacte-me para esclarecimentos assim que possível, mas apenas se você realmente tiver lido as instruções.

1.2 Parte 2 (1,5 pontos)

Utilize o scikit-learn e sua funcionalidade de GridSearch ("busca em grade", vista em sala de aula no dia 08/outubro/2019) para encontrar um conjunto de hiperparâmetros para diferentes algoritmos estudados nesta disciplina. Seus testes devem ser reportados em termos de acurácia média de 10 (dez) experimentos de validação cruzada estratificada do tipo 10-fold.

Utilize pelo menos 4 (quatro) algoritmos diferentes de classificação. Para cada um deles, realize uma busca em grade para um mínimo de 6 (seis) configurações diferentes de hiperparâmetros (por exemplo, duas opções de valores para um hiperparâmetros e 3 opções para outro). As acurácias médias das melhores configurações obtidas para cada classificador devem ser exibidas no arquivo PDF, assim como quais foram todas as configurações de hiperparâmetros testadas.

Se algum dos itens solicitados nesta parte estiver ausente, sua atividade poderá receber crédito zero nesta parte. Leia e releia estas instruções com atenção, para evitar decepções. Em caso de

dúvida, contacte-me para esclarecimentos assim que possível, mas apenas se você realmente tiver lido as instruções.

2 Entrega

A apresentação, organização e clareza do arquivo PDF também serão levadas seriamente em conta na atribuição de nota.

- Pontuação máxima pela atividade: 3,0 (três pontos).
- Entregáveis: código-fonte em Python; apenas um arquivo CSV gerado automaticamente pelo WEKA (e não por você, manualmente) contendo todos os resultados gerados pelo WEKA; e um arquivo PDF com as acurácias médias obtidas e hiperparâmetros utilizados, tanto para o WEKA quanto para o scikit-learn.
- Data de entrega: 27 de novembro de 2019, 23:59:59, via SIGAA. Não via e-mail.

3 Mais detalhes

• A atividade pode ser feita individualmente ou em dupla. Os nomes dos participantes da equipe **devem estar no arquivo PDF**, e **não** em mensagem via SIGAA. Mensagens enviadas via SIGAA, no momento da submissão, não serão levadas em conta para efeito de correção. Informações relevantes devem estar no PDF e no código.